

Извлечение и категоризация имен персоналий: Natasha, spaCy и ручная классификация.

На первом этапе осуществлялось извлечение имен собственных персоналий из поля НАЗВАНИЕ и поля ТЕКСТ исходного датасета, результаты сохранялись в соответствующих новых полях.

Для автоматического извлечения имен персоналий были использованы две мощные python-библиотеки обработки естественного языка для русского языка:

Библиотека **Natasha**: эта библиотека является специализированным инструментом для обработки русского языка, ориентированным на распознавание именованных сущностей (NER), в частности, на тег PER (Person), обозначающий людей. Её основная специализация – работа с русскоязычными именами и фамилиями.

Специальные функции библиотеки были использованы для токенизации, морфологического анализа, синтаксического разбора и, собственно, извлечения NER. Результаты извлечения были записаны в поле Names_Natasha.

Библиотека **spaCy**: для подтверждения и расширения результатов Natasha, а также для получения альтернативного взгляда на извлечение, я дополнительно использовала spaCy. Она представляет собой универсальную и мощную NLP-библиотеку. Для работы с русским текстом требовалась загрузка предобученной модели ru_core_news_lg. Эта модель эффективно распознаёт именованные сущности (NER), используя тег PER для людей.

Функция извлечения имен включала дополнительный морфологический анализ с использованием библиотеки **PyMorphy3**. Этот шаг был предпринят, так как в стихах часто встречаются слова с заглавной буквы в начале строки, которые не являются именами. Инструмент PyMorphy3 помогал отфильтровать только те слова, которые морфологически определяются как имена, фамилии или отчества. Функция также включала проверку на составные имена (например, «Борис Пастернак») и удаление дубликатов для получения уникальных имен. Все извлеченные имена (как через NER, так и через

PyMorphy3) нормализуются до их базовой формы (леммы) с помощью морфологического словаря для Natasha или аналогичные функции для spaCy и PyMorphy3. Это обеспечивает унифицированное представление имен, что необходимо для корректного подсчета упоминаний и дальнейшего анализа, предотвращая подсчет "Пушкина" и "Пушкину" как разных сущностей. Результаты были сохранены в поле Names_Spacy.

Обоснование комбинированного подхода: практический опыт показал, что ни одна из библиотек по отдельности не обеспечивает исчерпывающей полноты и точности извлечения имен собственных, особенно в условиях поэтического текста.

Сравнительный анализ работы библиотек. По результатам автоматического извлечения имен собственными, было установлено, что, в то же время не все имена извлекаются. Автоматическое выявление имён собственных выявило определённые погрешности: некоторые «лишние слова» (т.е. не-имена) ошибочно распознаются как имена, также отмечается недостаточная полнота выявления самих имён, что требует дальнейшего совершенствования алгоритмов идентификации.

Для оценки качества работы библиотек был проведён анализ ошибок, для чего полученный датасет был вручную размечен на наличие имён собственных и ошибочных данных. Это позволило выявить ошибки первого рода (ложноположительные срабатывания, когда неимя принималось за имя) и второго рода (ложноотрицательные срабатывания, когда имя не было распознано).

Эта ручная правка позволила не только очистить данные, но и получить количественную оценку производительности каждой из библиотек и их комбинации.

Примеры ошибок извлечения имен персон представлены в Таблице 1. Ошибки первого рода (ложноположительные) включали случаи, когда библиотеки принимали за имена топонимы или абстрактные понятия (например, «Петербург» извлечен библиотекой Spacy, а Natasha трансформировала слово в имя «Петр»). Ошибки второго рода

(ложноотрицательные) включали пропущенные имена из-за нестандартного написания или контекста (например, имя известного поп-исполнителя «Иванушка International» было пропущено Natasha, но извлечено библиотекой Spacy).

ID	СБОРН ИК	НАЗВАНИЕ	ГОД	Names_Natasha	Names_Spacy
3	МОЗАИ КА- ПАРАБО ЛА	Пожар в Архитектурн ом институте	1957	Кариночка Красильников	Трещат, Ватман, Красильникова
89	АХИЛЛЕ СОВО СЕРДЦЕ	Плач по двум нерожденным поэмам	1965	Сервантес, Борис Леонидович, Данте, Гамзатов, Ландау, Коперник, Ливанов, Гамлет	Борис Леонидович, Данте, Гамзатов, Ландау, Ливанов, Гамлет, Сервантес
431	ГАДАНИ Е ПО КНИГЕ	Путешествие из Ленинграда в Петербург	1994	Петр, Ростропович, Клико, Онегин, Винни-Пух, Пушкин	Петербург, Ростропович, Клико, Онегина, Винни- Пух, Пушкина
444	ГАДАНИ Е ПО КНИГЕ	Жуткий Крайзис Супер Стар	1999	Осип, Моника Левински, Моника, Настасья Филипповна, Нуреев, Андрей Белый, Кеннет Старр, Клинтон, Волков	Осип, Моника Левински, Настасья Филипповна, Нуреев, Андрей Белый, Клинтон, Волков, Иванушка (International), Кеннет, Кеннет Старр

Таблица 1. Примеры извлечения имен персоналий с использованием библиотек Natasha и Spacy.

ЖАНР	кол-во	кол-во слов	имена в названиях Natasha	ошибки Natasha	%	имена в названиях Spacy	ошибки Spacy	%
СТИХИ	1549	212 221	202	103	51	200	57	28
ПРОЗА	129	196 565	21	4	19	41	3	7

ЖАНР	кол-во	кол-во слов	имена в тексте Natasha	ошибки Natasha	%	имена в тексте Spacy	ошибки Spacy	%
СТИХИ	1549	212 221	4 251	2 444	57	3 798	2 992	78
ПРОЗА	129	196 565	7 648	1 274	17	5 743	1 466	25

Таблица 2. Статистика ошибок при извлечении имен персоналий с использованием библиотек Natasha и Spacy.

Применение библиотеки Natasha позволило обнаружить в названиях прозы 21 персональное имя, однако доля неверно идентифицированных объектов составила 19%. Библиотека SpaCy продемонстрировала более высокий

показатель точности, выделив 41 имя с уровнем ложноположительных результатов лишь в 7%.

Что касается экстрагирования персональных имён из заголовков поэтических произведений, использование библиотеки Natasha привело к обнаружению 202 единиц, при этом частота ошибок достигла показателя в 51%, тогда как применение библиотеки SpaCy дало возможность извлечь 200 имён, при уровне некорректно распознанных объектов в размере 28%.

Подробная статистика процесса извлечения имён персоналий как из прозаических, так и из поэтических текстов отражена в Таблице 2.