

Извлечение персоналий из каждого сегментированного текстового фрагмента осуществлялось посредством структурированных запросов (промптов). Разработка эффективных промптов является ключевым аспектом данного подхода, поскольку от их формулировки напрямую зависит качество и формат выходных данных. Ниже представлены детализированные инструкции, включенные в промпт:

Определение целевой задачи: LLM была проинструктирована на проведение комплексного анализа каждого стихотворения (или прозаической статьи) с последующим формированием структурированной записи.

Идентификация произведения: Для обеспечения прослеживаемости и возможности привязки извлечённых данных к конкретному произведению, LLM предписывалось включать уникальный идентификатор. В качестве такого идентификатора использовался заголовок стихотворения, если он был представлен в ВЕРХНЕМ РЕГИСТРЕ. В случаях, когда заголовок отсутствовал или был обозначен символической меткой («***»), LLM инструктировалась на использование первой строки текста.

Извлечение списка персоналий: ключевой задачей являлось формирование списка всех упоминаемых в тексте людей (включая имена мифологических, библейских персонажей, а также литературных и кино-героев).

Падеж и формат: LLM была строго проинструктирована на извлечение имён в именительном падеже. Требуемый формат вывода для каждой персоналии — «Фамилия Имя Отчество».

Обработка неполных ФИО: при отсутствии полного ФИО в тексте (например, упоминание только по имени или фамилии) модель должна была использовать доступные компоненты имени (например, «Имя Отчество» или только «Имя»). Для унификации представления и удобства последующей

обработки, извлеченные имена должны были быть отсортированы по алфавиту (по первой букве фамилии или имени, если фамилия отсутствует).

Обогащение и верификация данных о персоналиях: для каждого извлечённого имени предусматривалась необходимость предоставления дополнительной верификационной и атрибутивной информации.

Извлечение профессии/роли: важным аспектом являлось извлечение и указание профессии или роли персоны (например, «поэт» или «мифологический персонаж»), если таковая явно упоминалась в тексте или могла быть логически выведена из контекста.

Глубокий поиск и источники: В случаях, когда полное имя или профессия персоны не были явно указаны в исходном тексте, LLM предписывалось проводить «глубокий поиск» (deep research), с обязательным указанием источника информации. При этом категорически запрещалось генерировать вымышленные данные.

Проверка дубликатов: В рамках одного произведения LLM также осуществляла проверку на дубликаты имён для обеспечения уникальности записей внутри каждой стихотворной или прозаической единицы.

Формат финального вывода: Финальный формат вывода для каждой записи о персоне предусматривал строку, содержащую полное имя (Фамилия Имя Отчество) и соответствующую профессию/роль, разделённые символом табуляции (\t) для удобного последующего копирования в сводную таблицу (для формирования второго датасета со всеми извлеченными именами). В случаях, когда компоненты полного имени (например, отчество) отсутствовали в исходном тексте, LLM могла дополнять их на основе контекстуального анализа, следуя инструкциям по «deep research».